

Guía paso a paso: Cómo preparar los archivos raw y ejecutar el ETL

Esta guía está pensada para quien debe **generar o colocar los archivos de entrada** del proyecto y ejecutar el **ETL** (extracción y limpieza). El ETL lee archivos Excel desde `data/raw/`, los normaliza y guarda el resultado en `data/interim/`. Para el flujo mensual completo (ETL + inferencia), consulte [manual_usuario.md](#).

¿Qué hace el ETL?

- **Lee** archivos Excel (`.xlsx`) desde `data/raw/` organizados por fuente y mes.
- **Limpia y normaliza** los datos (nombres de columnas en minúsculas, tipos de dato, fechas al primer día del mes, deduplicación).
- **Escribe** en `data/interim/` archivos Parquet por año/mes (por ejemplo `data/interim/consumo/year=2025/month=03/consumo.parquet`).

Solo se procesan los **meses pendientes**: si un archivo ya tiene su Parquet en `interim/`, se omite salvo que se ejecute con `--overwrite`.

Estructura de carpetas en `data/raw/`

Debe existir una carpeta por cada **fuentes** y, dentro de ella, archivos con el nombre exacto:

```
data/raw/
├── inspecciones/
│   ├── inspecciones_2025_01.xlsx
│   ├── inspecciones_2025_02.xlsx
│   └── ...
└── consumo/
    ├── consumo_2025_01.xlsx
    ├── consumo_2025_02.xlsx
    └── ...
```

Nombre del archivo: `{fuente}_{AAAA}_{MM}.xlsx`

- **fuentes:** `inspecciones` o `consumo`
 - **AAAA:** año con 4 dígitos (ej. 2025)
 - **MM:** mes con 2 dígitos (ej. 01, 02, 12)
-

1. Archivos de inspecciones

Columnas requeridas (según el ETL actual)

El ETL espera, tras normalizar los nombres de columnas (minúsculas, sin tildes, espacios → `_`), al menos estas columnas en los Excel de inspecciones:

Columna en el Excel (normalizada)	Descripción
servicio_suscrito	Identificador del servicio/contrato. Se convertirá a contrato . Debe tener 9 caracteres después de limpiar.
fecha	Periodo de la inspección en formato YYYYMM (por ejemplo 202501 para enero 2025). El ETL lo convierte a fecha YYYY-MM-01 .
clasificacion_resultado	Clasificación del resultado (Fraude , Anomalía , Sin definición , etc.). Se usa para crear el campo is_fraud .

Otras columnas (como **solicitud**) son opcionales: si existen, se conservan; si no, el ETL igual funciona.

Reglas clave en el ETL:

- Los nombres de columna se normalizan (mayúsculas, tildes y espacios se corrigen).
- **servicio_suscrito** → **contrato**.
 - Se filtran filas donde **contrato** tenga exactamente 9 caracteres y no sea nulo.
- **fecha** se interpreta con formato **%Y%m**.
 - Si no cumple ese formato, se descarta la fila.
- **clasificacion_resultado**:
 - Se descartan filas con **clasificacion_resultado** == "**Sin definición**".
 - Se crea **is_fraud** = 1 si **clasificacion_resultado** es "**Fraude**" o "**Anomalía**", 0 en otro caso.
- Si hay varias filas para el mismo (**contrato**, **mes**), el ETL se queda con la de mayor **is_fraud** (si hay algún fraude/anomalía en el mes, el contrato queda marcado como 1 para ese mes).

Ejemplo de contenido (inspecciones_2025_01.xlsx)

servicio_suscrito	fecha	clasificacion_resultado	solicitud (opcional)	...
000123456	202501	Sin definición	1234	...
000123456	202501	Fraude	5678	...
000234567	202501	Anomalía	9012	...

Tras el ETL:

- **contrato** será "**000123456**", "**000234567**", etc.
- **date** será **2025-01-01** para todas las filas de enero 2025.
- **is_fraud** será 1 si hay alguna fila con Fraude o Anomalía para ese contrato y mes.

2. Archivos de consumo

Columnas requeridas (según el ETL actual)

El ETL espera, tras normalizar los nombres de columnas, al menos:

Columna en el Excel (normalizada)	Descripción
niu	Identificador del contrato. Se convertirá a contrato .
fecha_mes	Periodo de consumo en formato YYYYMM (ej. 202501). Se convierte a fecha YYYY-MM-01 .
consumo	Consumo del periodo. Valores negativos se descartan.

Otras columnas que el ETL usa si existen:

- instalacion** (texto): se limpia y mantiene.
- subcategoria_estrato** (texto): se limpia y mantiene.
- localidad, municipio** (texto): se limpian y mantienen.
- barrio** (texto): se rellena con **"sin_dato"** si falta.
- determinacion_consumo** (texto): si existe, se limpia y mantiene.

Reglas clave en el ETL:

- Los nombres de columna se normalizan.
- niu** → **contrato**.
- fecha_mes** se interpreta con formato **%Y%m**. Filas con fecha inválida se descartan.
- Se crea una columna **date** con el primer día del mes (**YYYY-MM-01**).
- consumo**:
 - Si es NaN o < 0, se convierte a **None** (se considerará como faltante).
- Se ordena por **date** (y eventualmente otras columnas) para dejar los registros limpios y en orden temporal.

Ejemplo de contenido (consumo_2025_01.xlsx)

niu	fecha_mes	consumo	localidad	municipio	barrio	determinacion_consumo
-----	-----	-----	-----	-----	-----	-----
000123456	202501	25	NORTE	CIUDAD	CENTRO	NORMAL
000123456	202501	-5	NORTE	CIUDAD	CENTRO	NORMAL
000234567	202501	32	SUR	CIUDAD	GRANADA	NORMAL
000345678	202501	18	ESTE	CIUDAD	sin_dato	NORMAL

- El valor -5 se considera inválido y se descarta.
- Se mantiene una fila por (**contrato, mes**) tras la limpieza y ordenamiento, con el consumo válido.

3. Resumen: generar los archivos raw

1. **Crear las carpetas** **data/raw/inspecciones/** y **data/raw/consumo/** (si no existen).
2. **Exportar o generar** los Excel con las columnas indicadas para cada fuente:

- Inspecciones: `servicio_suscrito`, `fecha` (YYYYMM), `clasificacion_resultado` (y opcionales).
 - Consumo: `niu`, `fecha_mes` (YYYYMM), `consumo` (y opcionales).
3. **Nombrar cada archivo** exactamente: `inspecciones_AAAA_MM.xlsx` y `consumo_AAAA_MM.xlsx`.
 4. **Colocar cada archivo** en la carpeta de su fuente.
 5. Revisar que **fechas y números** estén en formato coherente (fechas tipo `202501`, consumo numérico, textos sin caracteres extraños).
-

4. Ejecutar el ETL (desde la raíz del proyecto)

Con los archivos raw ya en su sitio:

1. Abra una terminal en la **raíz del proyecto** (donde están `config/`, `scripts/`, `data/`).
2. (Opcional) Active el entorno virtual si lo usa.
3. Ejecute:

```
python scripts/run_etl.py
```

- El ETL lee la configuración en `config/config.yaml` (rutas en `paths`, fuentes en `etl.sources`).
- Solo procesa **meses que aún no tienen Parquet** en `data/interim/`.

Para **reprocesar todos los meses** (sobrescribir lo que ya está en interim):

```
python scripts/run_etl.py --overwrite
```

Para usar otro archivo de configuración:

```
python scripts/run_etl.py --config otro.yaml
```

5. Ejecución alternativa: desde el notebook (poc/1_etl.ipynb)

Si prefiere ejecutar el ETL de forma **interactiva** (celda a celda, viendo el resumen de lo procesado), puede usar el notebook en la carpeta `poc/`:

1. Abra la terminal en la **raíz del proyecto** (donde están `config/`, `scripts/`, `poc/`, `data/`).
2. (Opcional) Active el entorno virtual si lo usa (por ejemplo: `.\qenv\Scripts\activate` en Windows).
3. Inicie Jupyter Lab: `jupyter lab` (o abra el proyecto en VS Code y abra el notebook desde ahí).
4. En el panel de archivos, entre en la carpeta `poc` y abra `1_etl.ipynb`.
5. Asegúrese de que el **kernel** usa el entorno del proyecto (donde están instaladas las dependencias).
6. Ejecute las celdas en orden (**Run All** o celda por celda con Shift+Enter).

El notebook carga la configuración desde `config/config.yaml` (rutas, `etl.sources`, `etl.overwrite`) y llama a la misma lógica que el script; el resultado es el mismo: los Parquet se escriben en `data/interim/` por

fuentes y años/meses. No es necesario duplicar parámetros: basta con tener los archivos raw en su sitio y la configuración correcta.

Resumen: (1) Archivos raw en `data/raw/` según esta guía. (2) Abrir `poc/1_etl.ipynb`. (3) Ejecutar todas las celdas. (4) Revisar los Parquet en `data/interim/`.

6. Dónde está el resultado

Tras una ejecución correcta:

- **Inspecciones:** `data/interim/inspecciones/year=AAAA/month=MM/inspecciones.parquet`
- **Consumo:** `data/interim/consumo/year=AAAA/month=MM/consumo.parquet`

Si en `config/config.yaml` está definido `paths.logs` (por ejemplo `data/logs`), cada ejecución del ETL escribe además un archivo de log (ej. `etl_20250214_120000.log`) para depuración.

7. Si algo falla

- **"Directorio ... no existe, saltando"**
Cree la carpeta correspondiente en `data/raw/` (por ejemplo `data/raw/inspecciones/`) y coloque ahí los archivos con el nombre `{fuente}_{AAAA}_{MM}.xlsx`.
- **Error al leer el Excel o columna no encontrada**
Compruebe que el archivo tiene las **columnas requeridas** con nombres que, una vez normalizados (minúsculas, sin tildes, espacios → `_`), coincidan con los de esta guía (p. ej. `contrato`, `fecha`, `resultado` para inspecciones; `año`, `mes` para consumo).
- **"No hay meses pendientes"**
Todos los archivos que hay en `data/raw/` para esa fuente ya tienen su Parquet en `data/interim/`.
Para volver a procesarlos, use `python scripts/run_etl.py --overwrite`.

Para más detalle sobre el flujo mensual y la inferencia, consulte [manual_usuario.md](#).